TRABAJO PRACTICO 3

INFORME

Parte I: Creación de variables y más estadística descriptiva.

Creación de variables.

Para la variable “edad2” se elevó al cuadrado la variable CH06. Al momento de definir la variable “educ” se establecieron las condiciones bajo las que se contarán los años de educación, a saber:

Años de educación, (CH12)

1 = Jardín/preescolar - educ. formal = 0 2 = Primario - educ. formal = 6 3 = EGB - educ. formal = 9 4 = Secundario - educ. formal = 12 5 = Polimodal - educ. formal = 12	6 = Terciario - educ. formal = 14 7 = Universitario - educ. formal = 17 8 = Posgr. universitario - educ. formal =19 Educación especial (discapacidad) - educ. formal = 0

Para el caso de que no haya completado el nivel más alto cursado (CH13 = 2), se definió que la cantidad de años de educación formal sea el nivel más alto completado, sumado a la respuesta en CH14.

Al crear “horastrab” se definió que sea igual a la suma los valores de las columnas PP3E_TOT (Horas de trabajo de ocupación principal) y PP3F_TOT (Horas de trabajo de otras ocupaciones)

La variable “nhogar” se creó bajo la premisa de la siguiente frase en el registro de la EPH

> En la de Personas (archivo usu_individual.txt), todos los miembros del hogar tienen el mismo CODUSU y NRO_HOGAR, pero se diferencian por el número de COMPONENTE.

La columna COMPONENTE define la cantidad de personas que viven dentro de un hogar, delimitado por CODUSU y NRO_HOGAR.

A continuación se muestran los gráficos de las variables:

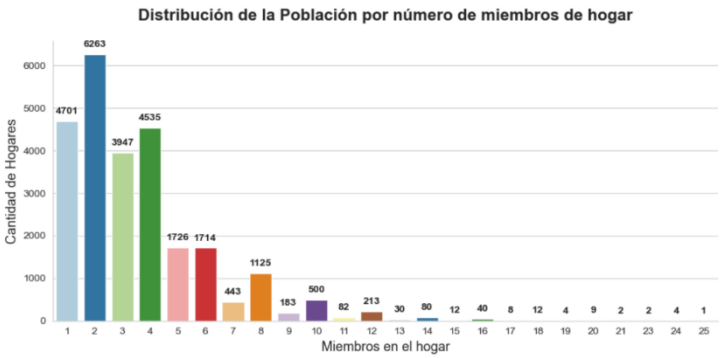

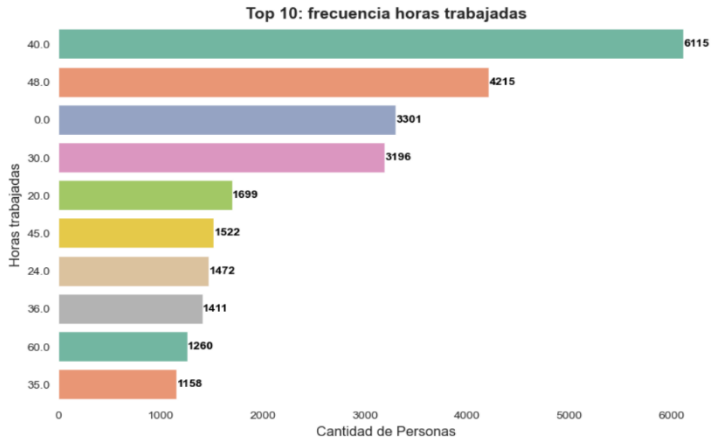

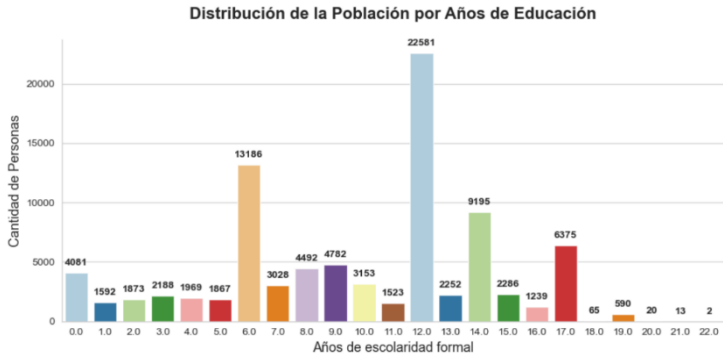

Estadística descriptiva

	NRO_HOGAR	PONDERA	CH06	NIVEL_ED	PP04C	P21	P47T	PP04G	PP3E_TOT	PP3F_TOT	edad2	educ	horastrab	nhogar
count	91475.00	91475.00	90851.00	91475.00	34864.00	84233.00	81052.00	40401.00	40211.00	40393.00	90851.00	88352.00	40401.00	91475.00
mean	1.03	649.80	36.80	3.75	5.03	197145.57	327321.38	9.03	33.57	1.24	1839.56	9.75	36.72	5.37
std	0.64	862.56	22.03	1.74	3.79	442957.53	576952.09	3.30	18.04	4.87	1851.59	4.60	46.07	3.38
min	1.00	21.00	1.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	1.00
25%	1.00	178.00	18.00	3.00	1.00	0.00	0.00	8.00	20.00	0.00	324.00	6.00	24.00	3.00
50%	1.00	320.00	35.00	4.00	5.00	0.00	150000.00	11.00	36.00	0.00	1225.00	12.00	40.00	4.00
75%	1.00	667.00	53.00	5.00	8.00	250000.00	445000.00	11.00	45.00	0.00	2809.00	12.00	48.00	7.00
max	72.00	8685.00	103.00	7.00	12.00	25000000.00	32600000.00	13.00	95.00	76.00	10609.00	22.00	1998.00	25.00

De la tabla se puede destacar que tanto la mediana como el tercer cuartil de los años de educación es igual, es decir que para el 75% de la muestra presenta dificultades para estudiar más años luego del colegio secundario/polimodal.

Para las horas trabajadas, la mitad trabaja más de 40 horas semanales, lo que le corresponde a 8 horas diarias. También se puede ver que el 50% de los encuestados vive en hogares de menos de 4 habitantes, con un outlier de 25 habitantes.

Matriz de correlación

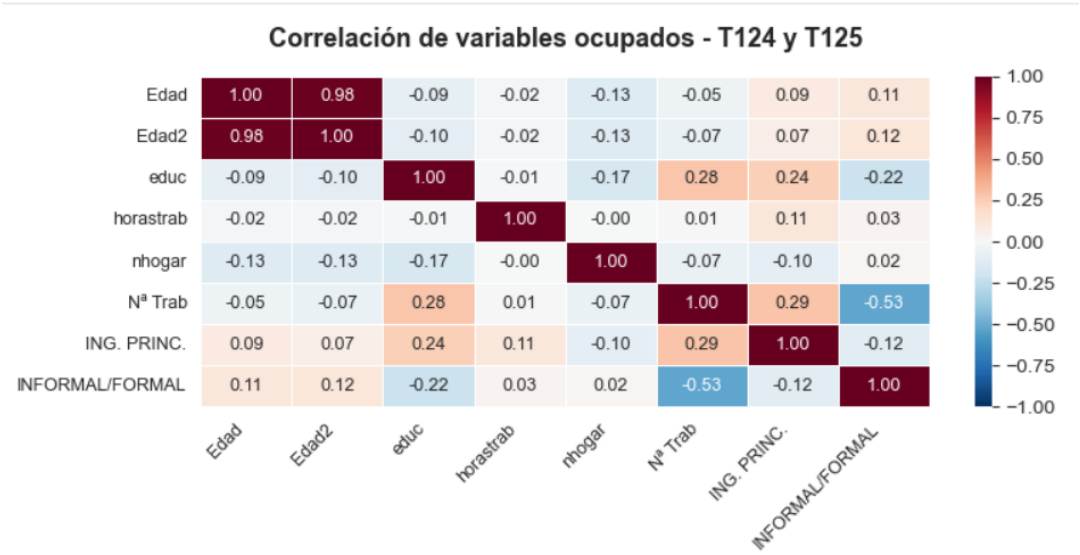

De esta matriz de correlación se pueden obtener varias conclusiones. La edad está muy poco correlacionada con todas las variables, algo contraintuitivo para los casos de ingreso y años de educación. La educación tiene una correlación inversa para definir la formalidad de una persona, y dado que en este caso Informal=1 y Formal=0, a más años de educación, menos probabilidades hay de ser informal. También presenta una correlación positiva con el ingreso

Las horas trabajadas tienen una leve correlación positiva con el ingreso principal, mientras que el número de personas en el hogar tiene una correlación negativa con los años de educación, por lo que cuantas mas personas vivan en un hogar, mayores son las chances de que tengan pocos años de educación

Los mayores valores de correlación están en la cantidad de trabajadores que hay en la ocupación de la persona, con una fuerte correlación negativa con la Informalidad. Cuantas más personas trabajen en su ocupación, menos probabilidad hay de ser informal. También, hay una importante correlación positiva con el ingreso.

Parte II: Métodos no Supervisados

Luego de realizar la transformación, en media 0 y std. Dev 1, de las variables mencionadas en la consigna, se aplicó PCA. Surgió un problema debido a la cantidad de valores nulos que tiene Nª Trab. e Ing. Princ., y debido a que PCA no admite valores nulos se abrieron dos posibilidades. La primera, sugerida por Gemini, es utilizar IterativeImputer para que, no inventa un número fijo (como podría ser la media), sino que estima el ingreso de la persona basándose en su edad, educación y horas trabajadas.

La segunda solución es eliminar las filas nulas, siendo un total de 11.077, y eliminar el 28% de la muestra.

Los resultados se presentan a continuación: (primeros cuatro componentes)

Varianza explicada (Iterative Imputer): [0,30 0,22 0,15 0,13]

Varianza explicada (Caso Dropna): [0,31 0,25 0,15 0,11]

Al tener resultados muy parecidos en ambos casos, decidimos quedarnos con la opción de IterativeImputer por la razón una mayor cantidad de filas.

<u>Gráfico de dispersión</u>

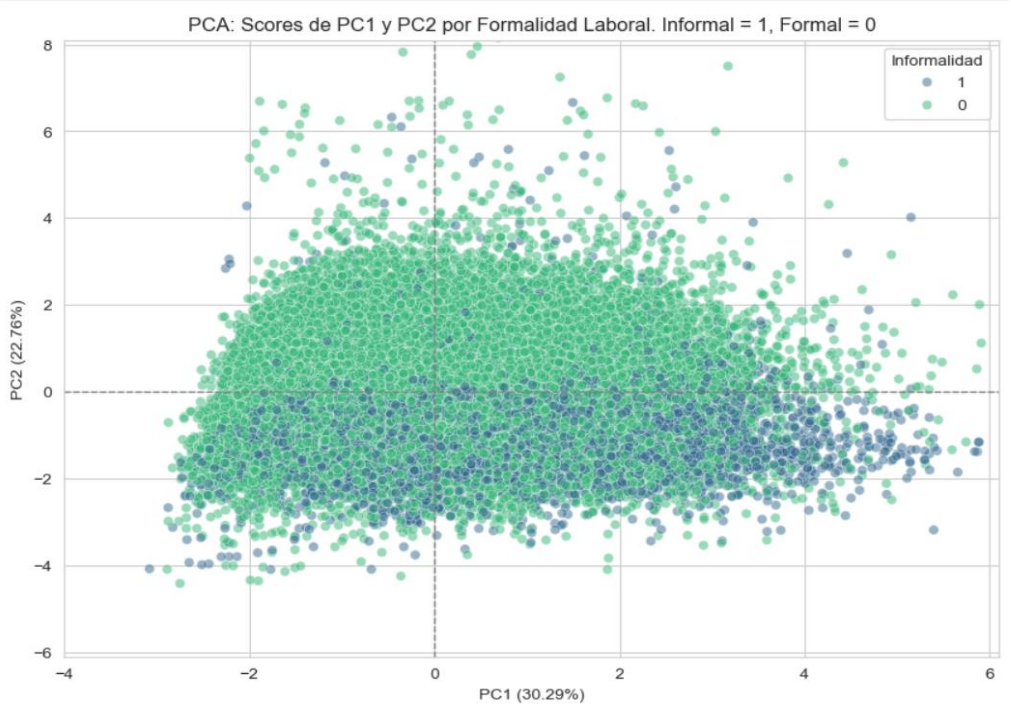

En el gráfico se puede observar que los trabajadores formales están repartidos en los cuatro cuadrantes mientras que los trabajadores informales se encuentran en su mayoría en los valores negativos del PC2 y están distribuidos en el PC1.

<u>Ponderadores</u>

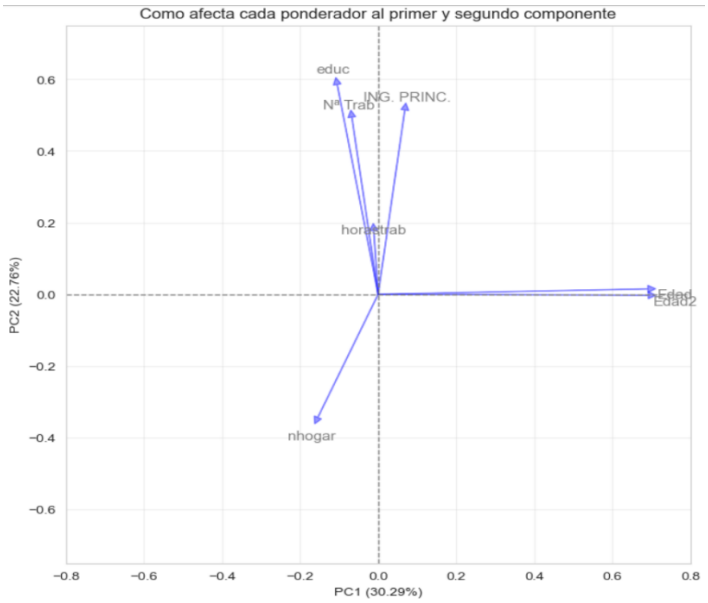

Se puede sacar conclusiones según cada variable

Edad: modifica significativamente PC1 Educ: modifica significativamente PC2 y mínimamente PC1 Nª Trab: modifica significativamente PC2	Horastrab: modifica mínimamente PC2 Nhogar: modifica significativamente PC2 y mínimamente PC1 Ing. Princ.: modifica significativamente PC2 y mínimamente PC1

Proporción de varianza explicada

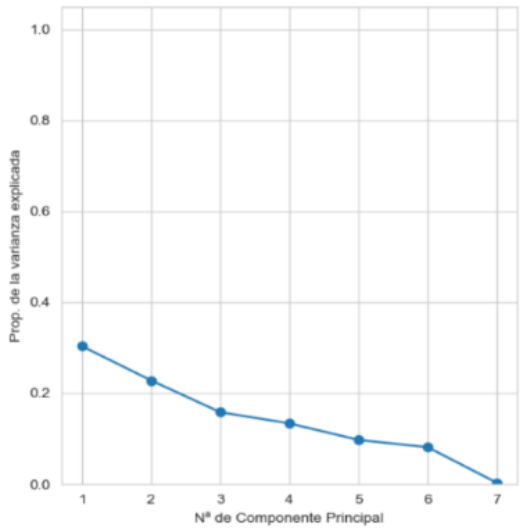

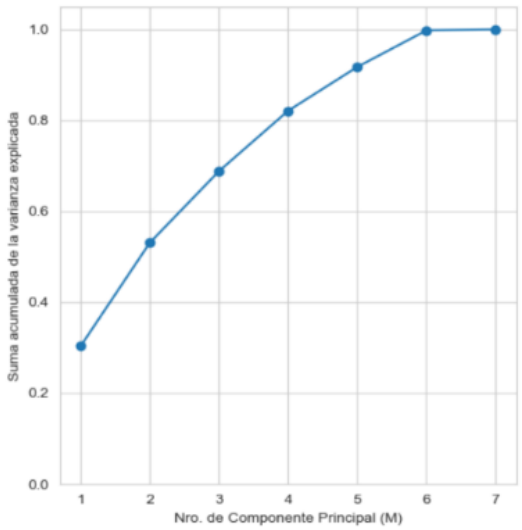

Se observa que con 4 componentes se supera el 80% de la varianza acumulada. Es posible reducir el dataset de 7 variables a 4 sin una pérdida significativa de información. Observando la matriz de correlaciones, las variables a eliminar serían edad2, horastrab y nhogar.

Cluster

Luego de aplicar la transformación, se armó un grafico que contiene en el eje Y el ingreso de su ocupación principal y en eje X las horas trabajadas semanalmente. Para un total de 2 clusters.

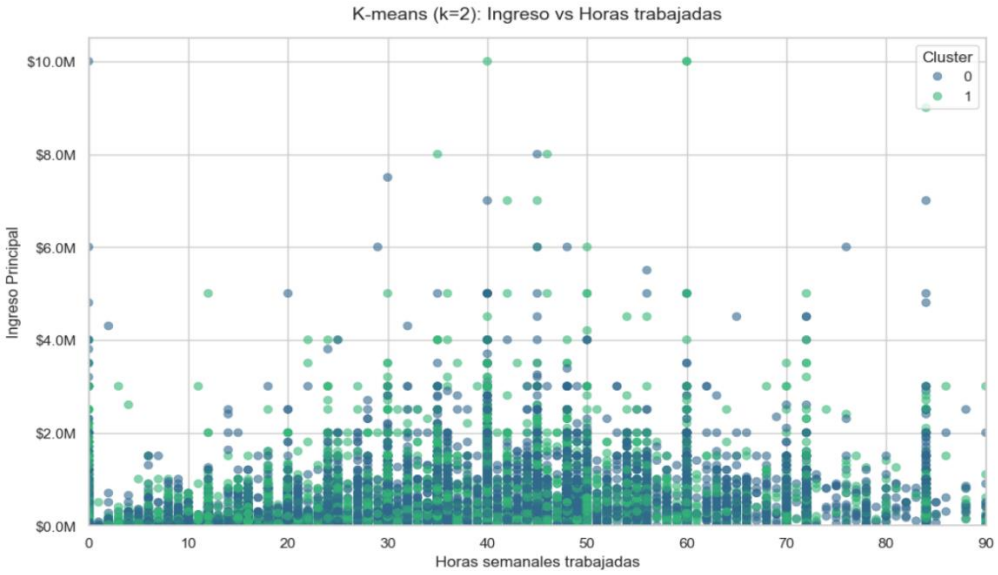

Dos clusters no son suficientes, ya que están mezclados entre sí. Por el método elbow lo correcto sería tener siete clusters.

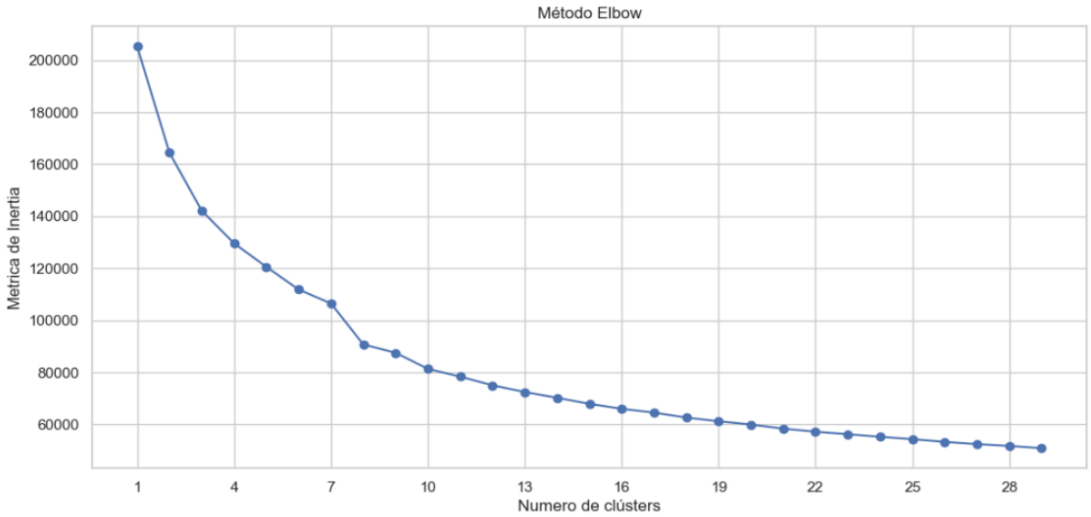

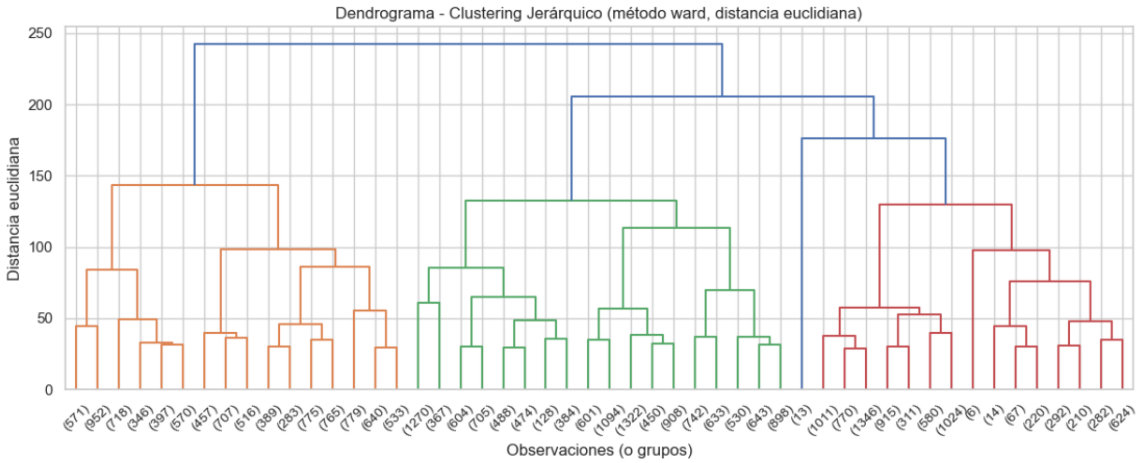

En esta muestra de las últimas 30 fusiones, se utlilizo el método Ward que minimiza la varianza interna y con un resultado de clusters mucho más balanceados y separados, mostrando que lo optimo es usar 3 clusters

Parte III: Uso de la IA

La utilización de herramientas de inteligencia artificial resultó de gran ayuda a lo largo del trabajo práctico, especialmente en dos aspectos: la mejora en la legibilidad de los gráficos y la implementación de funciones complejas con múltiples condicionales. Permitió optimizar la presentación visual de los gráficos, sugiriendo mejores elecciones de colores, etiquetas más claras, títulos más descriptivos y ajustes en escalas y formatos que facilitaron la interpretación de los resultados. Por otro lado, también fue fundamental para la programación, ya que brindó asistencia en la construcción de funciones más sofisticadas que requerían la combinación de varios condicionales lógicos.

Apéndice. Prompts para IA

Se utilizó Gemini en su totalidad

Dime como utlizar la función merge en Python en caso de querer agregar columnas a un dataset ya exsistente. Comenta los significados de cada línea

Nota: se terminó utilizando la función concatenar

Define una función en Python usando, en caso de ser necesario, pandas o numpy, que cumpla con las siguientes condiciones.

Años de educación, en CH12 y con CH13 = 1

1 = Jardín/preescolar - educ. formal = 0

2 = Primario - educ. formal = 6

3 = EGB - educ. formal = 9

4 = Secundario - educ. formal = 12

5 = Polimodal - educ. formal = 12

6 = Terciario - educ. formal = 14

7 = Universitario - educ. formal = 17

8 = Posgrado universitario - educ. formal = 19

9 = Educación especial (discapacidad) - educ. formal = 0

En caso de CH13 = 2, sumar el valor de CH14 al nivel de educación anterior.

Dame un código para un grafico de barras horizontales, utilizando seaborn, que sea prolijo y profesional, utilizando una paleta de colores pasteles

Dado que estoy trabajando con la EPH, como puedo solucionar el hecho de que contenga NaN a la hora de aplicar PCA?